

이론통계학 2 Project #1

3 조 242STG28 황수연 252STG26 이휘민 262STG01 강재서 262STG09 조유나

역할분담 <Part A> : 이휘민, <Part B-1>: 조유나, <Part B-2> : 강재서, <Part C, D> : 황수연

<Part A> DRAM 분기별 선적자료 (1982-1995)

1. 256K-DRAM 분기별 선적자료의 시계열도표




그림 1. 256K-DRAM 분기별 선적량 $S(t)$

256K-DRAM의 선적량은 초기 구간에 완만히 증가하다가, 중반 이후 급격히 상승하고, 후반부로 갈수록 증가폭이 둔화되는 전형적인 S자형(로지스틱형) 확산 패턴을 보인다. 따라서 Bass/Logistic/Gumbel과 같은 확산모형을 적용하는 것이 타당하다고 볼 수 있다.

2. Bass / Logistic / Gumbel 모형의 OLS 추정 및 상대오차

n	모형	p	q	$\hat{m}$	상대오차(%)
15	Bass	0.00067	0.681	892,463	-81.73
15	Logistic	0	0.688	881,246	-81.96
15	Gumbel	-	0.149	5,890,455	+20.57
30	Bass	0.00497	0.230	4,147,325	-15.11
30	Logistic	0	0.251	4,049,601	-17.11
30	Gumbel	-	0.127	5,007,992	+2.51
51	Bass	0.00583	0.194	4,621,535	-5.40
51	Logistic	0	0.211	4,606,019	-5.72
51	Gumbel	-	0.136	4,740,560	-2.97

데이터가 부족한 초기($N=15$)에는 Bass-Logistic 모형이 m 을 극심하게 과소추정 하는 반면, Gumbel 모형은 오히려 과대추정 하지만 오차 자체는 상대적으로 작다. N 이 증가함에 따라 세 모형 모두 m 추정치가 참값에 근접해가며, 특히 Bass-Logistic의 개선폭이 두드러진다. 이는 확산모형의 모수 추정이 관측 구간 초기에는 구조적으로 불안정하며, 충분한 시계열이 축적되어야 신뢰할 수 있는 추정치를 제공한다는 확산모형의 일반적 한계를 보여준다.

실제 총 수요값 m_{true} 는 $n=51$ 시점까지의 누적판매량(Y_{51})보다 약간 크다는 사실을 고려하여 5%의 여유를 더하여 계산하였다. ($m_{\text{true}} = Y_{51} \times 1.05 = 4,885,584$)

3. MSE 및 Q-Q plot 을 이용한 최적모형 비교

n	모형	MSE	MSE 기준	상대오차 (%)	Q-Q R ²	Q-Q 기준	상대오차 (%)
15	Bass	1.04×10^7	★	-81.7	0.980	★	-88.5
15	Logistic	1.07×10^7			0.980		
15	Gumbel	2.47×10^7			0.958		
30	Bass	5.14×10^8			0.971	★	-22.0
30	Logistic	7.07×10^8			0.966		
30	Gumbel	1.96×10^8	★	+2.51	0.940		
51	Bass	4.40×10^8			0.963	★	+1.47
51	Logistic	6.54×10^8			0.956		
51	Gumbel	3.08×10^8	★	-2.97	0.926		

두 지표는 N=15 에서는 최적 모형이 Bass 로 일치하지만, N=30-51 에서는 서로 다른 모형을 최적으로 지목하는 불일치가 나타난다: MSE 기준으로는 Gumbel 이, Q-Q R² 기준으로는 Bass 가 우수하다.

최적의 모형이 불일치하는 N=30, 51 에서 평가 지표별 최적모델의 상대오차를 비교하면, N=30 일 때에는 MSE 기반 최적 모델인 Gumbel 이 Bass 에 비해 압도적으로 좋은 성능을 보인다. 그러나 N=51 일 때에는 오히려 Bass 모형이 Gumbel 보다 우세하다는 것을 확인할 수 있다.

4. 1M-DRAM 에 대한 모형 비교

n	모형	$\hat{m}$	상대오차(%)
40	Bass	3,667,424	+19.30
40	Logistic	3,601,517	+17.16
40	Gumbel	5,463,032	+77.75




그림 2. 1M-DRAM 시계열 및 모형별 Q-Q plot

1MD 자료(N=40)에서는 문항 2-3 의 256KD 결과와 정반대의 패턴이 관찰된다. 256KD 에서는 Gumbel 의 상대오차가 가장 작았던 반면, 1MD 에서는 Gumbel 의 오차(77.75%)가 세 모형 중 압도적으로 크며, 오히려 Bass-Logistic(17~19%대)이 상대적으로 양호한 결과를 보인다. Q-Q Plot 에서도 Gumbel 모형의 R²이 Bass-Logistic 대비 낮게 나타나 이론분포와 관측 구매시점 간 정렬이 상대적으로 부정확함을 시사한다. 결론적으로 Bass 또는 Logistic 모형을 선정하는 것이 바람직하다.

실제 총 수요값 m_{true} 는 $n=40$ 시점까지의 누적판매량(Y_{40})보다 약간 크다는 사실을 고려하여 10%의 여유를 더하여 계산하였다. ($m_{true} = Y_{40} \times 1.10 = 3,073,546$)

<Part B-1> : COVID-19 사망자 예측

1. 영국 일별 신규 Covid-19 사망자수(S_t) 및 누적 사망자수(Y_t) 시계열 도표




그림 3. 영국 일별 신규 사망자수 $S(t)$




그림 4. 영국 누적 사망자수 $Y(t)$

일일 신규 사망자 수 그래프에서는 초기에는 사망자 수가 증가하면서 코로나 19 유행이 확대되는 모습을 확인할 수 있으며, 이후 일정 시점에서 정점을 형성한 뒤 감소하는 양상이 나타난다. 이는 유행이 정점에 도달한 후 새로운 사망자의 발생 속도가 점차 감소했음을 의미한다. 일일 사망자 수가 증가하는 시기에는 누적 사망자 수의 증가 속도도 빨라지고, 일일 사망자 수가 감소하면 누적 사망자 수의 증가 속도 역시 느려진다.

따라서 두 그래프를 함께 살펴보면 코로나 19 유행의 진행 상황과 사망 발생 속도, 그리고 최종적으로 누적되는 사망 규모를 동시에 파악할 수 있다. 이러한 누적 사망자 Y_t 와 일일 사망자 S_t 의 관계는 이후 Bass, Logistic, Gumbel 모형을 이용하여 최종 누적 사망 규모 m 을 추정하는 데 사용된다.

2. Bass / Logistic / Gumbel 모형의 OLS 추정 및 상대오차

n	모형	p	q	$\hat{m}$	상대오차(%)
20	Bass	0.000933	0.33324	4,087.872	-92.93
20	Logistic	-	0.48941	1,575.725	-97.27
20	Gumbel	-	0.05644	102,284.911	+76.00
30	Bass	0.000733	0.25020	17,437.118	-69.83
30	Logistic	-	0.41992	7,926.372	-86.28
30	Gumbel	-	0.05541	120,252.102	+108.09
50	Bass	0.002230	0.14737	38,535.21	-33.32
50	Logistic	-	0.35470	26,724.06	-53.76
50	Gumbel	-	0.05945	72,238.32	+25.00

학습자료의 크기(n)가 증가할수록 더 많은 관측자료를 이용하기 때문에 최종 누적 사망자 m 에 대한 추정값이 실제 누적 사망자 규모에 가까워지는 것을 확인할 수 있다. 특히 초기의 적은 자료만 사용한 경우에는 유행의 전체적인 형태를 충분히 관찰하지 못하기 때문에 m 의 추정에 큰 오차가 발생할 수 있다.

상대오차가 음수이면 모형이 실제 최종 누적 사망자 수보다 작게 예측했음을 의미하고, 양수이면 실제보다 크게 예측한 것을 의미한다. 또한 상대오차의 절댓값이 작을수록 실제 누적 사망자 수에 가까운 예측을 한 것이므로 모형의 최종 규모 예측이 상대적으로 우수하다고 판단할 수 있다.

Bass 모형과 Logistic 모형의 상대 오차가 모두 음수인 것을 보아, 두 모형에서의 최종 누적 사망자의 값이 실제보다 작게 추정되는 경향이 있는 것으로 보이고 Gumbel 모형의 상대오차는 모두 양수인 것을 보아 해당 모형에서는 최종 누적 사망자의 값이 실제보다 많이 추정되는 경향이 있는 것으로 보인다.

3. 최적 모형 선택

세 모형의 추정값을 비교한 결과, Gumbel 모형이 $n=30$ 일 때 큰 변동성을 보였지만 $n=50$ 일 때 m 의 추정값이 72,238.32로 최신 누적 값에 가장 가까웠으며, 다른 두 모형에 비해 상대적으로 낮은 상대오차를 보였다. 따라서 Gumbel 모형을 최적의 모형으로 선정하였다.

4. Gumbel 모형의 OLS / NLSE / MLE 추정값 비교

n	OLS	NLSE	MLE	OLS 오차(%)	NLSE 오차(%)	MLE 오차(%)
20	102,284.9	222,294.8	175,865.7	+77.00	+284.67	+204.32
30	120,252.1	112,989.0	183,066.0	+108.09	+95.52	+216.78
50	72,238.32	48,481.99	52,079.41	+25.00	-16.11	-9.88

앞에서 선택한 Gumbel 모형에 대해 OLS, NLSE, MLE 방법을 이용하여 최종 누적 사망자 수(m)을 추정하고, 최신 누적 사망자 수인 57,789 명을 실제 값으로 하여 상대오차를 비교하였다.

먼저 OLS 방법은 세 경우 모두 상대오차가 양수이므로 실제 값보다 m 을 크게 추정하였다. 특히 $n=50$ 에서는 상대오차가 25.0%까지 감소하여 초기 자료만 이용했을 때보다 정확도가 개선되었다. OLS는 선형회귀 형태로 모형을 변환하여 추정하기 때문에 계산이 간단하고 구현이 쉽다는 장점이 있다. 반면, Gumbel 모형의 비선형적인 구조를 선형 형태로 변환하는 과정에서 발생하는 오차와 자료의 초기값에 대한 민감성 때문에 최종 (m)을 과대 추정할 가능성이 있다.

NLSE 방법은 $n=20, 30$ 에서 큰 상대오차를 보였지만, $n=50$ 에서는 -16.1%로 크게 개선되었다. 특히 $n=50$ 에서는 실제 값보다 약 16.1% 작게 추정하여 세 경우 중 절댓값 기준으로 가장 작은 상대오차를 보였다. NLSE는 실제 일별 사망자 수와 Gumbel 모형에서 예측한 일별 사망자 수의 차이를 직접 최소화하기 때문에 원래의 비선형 모형을 그대로 이용할 수 있다는 장점이 있다. 그러나 비선형 최적화 과정에서 초기값의 영향을 받을 수 있으며, 충분한 자료가 없는 경우 안정적인 추정이 어려울 수 있다는 단점이 있다.

MLE 방법은 $n=20, 30$ 에서는 상대오차가 매우 크게 나타났지만, $n=50$ 에서는 -9.88%로 실제 값에 가장 가까운 추정값을 얻었다. MLE는 관측된 자료가 발생할 가능성을 가장 크게 만드는 모수를 추정하는 방법으로, 통계적 이론이 명확하고 표본이 충분할 경우 효율적인 추정량을 얻을 수 있다는 장점이 있다. 반면, 우도함수의 비선형적인 최적화가 필요하고 초기값이나 최적화 과정에 따라 추정 결과가 영향을 받을 수 있다는 단점이 있다.

<Part B-2 (1)> : 미국 분기별 HIV/AIDS 확산예측

1. 미국 분기별 HIV/AIDS 감염자자료(s_t) 시계열 도표




그림 5. 미국 분기별 HIV/AIDS 신규 감염자수

미국 분기별 HIV/AIDS 신규 감염자수 s_t 는 $t \approx 46$ (1992 년경) 부근에서 정점(약 22,600 건)을 찍고 감소하는 전형적 종모양 확산 패턴을 보인다.

2. Bass / Logistic / Gumbel 모형의 OLS 추정 및 상대오차

n	모형	p	q	$m^{\wedge}$	상대오차(%)	RMSE
20	Bass	0.00167	0.21932	109,605	-83.63	100.3
20	Logistic	0	0.24562	88,572	-86.77	141.1
20	Gumbel	-	0.05028	784,235	+17.15	99.2
40	Bass	0.00204	0.11940	452,572	-32.40	701.6
40	Logistic	0	0.13659	403,336	-39.75	898.5
40	Gumbel	-	0.04608	886,444	+32.42	462.9
65	Bass	0.00157	0.09631	787,165	+17.59	1101.5
65	Logistic	0	0.10331	773,275	+15.51	1315.8
65	Gumbel	-	0.04832	1,000,860	+49.51	1494.0




그림 6. n 변화에 따른 상대오차와 RMSE 비교

n=20 에서 Bass-Logistic 은 m 을 실제의 15% 수준으로 심하게 과소평가(-83~-87%)하지만, Gumbel 은 이미 +17.15%로 근접한다. 반대로 n 이 늘수록 Bass-Logistic 오차는 0%에 수렴하는데 Gumbel 은 +49.51%까지 커진다 — Gumbel 은 초기자료엔 강하지만 정점-감소구간을 포함할수록 과대추정이 심해진다.

3. 최적 모형 선택

세 모형의 추정값을 비교한 결과, n=20 의 Gumbel 모형(RMSE=99.2, 상대오차 +17.15%)을 최적의 모형으로 선정하였다. 해당 모형은 전체 9 개 조합 중 RMSE 가 가장 낮아 적합도가 최우수하고, n=20 이라는 적은 관측치만으로도 m 추정 상대오차가 +17.15%로 준수해, 동일 n 의 Bass, Logistic(-83~87%, 사실상 예측 실패)보다 실용적 가치가 크다. 다만 n 이 커질수록 Gumbel 의 RMSE 와 상대오차가 급격히 나빠지는 한계가 있어(정점 이후 감소 구간을 Bass, Logistic 만큼 유연하게 반영하지 못함), 자료가 누적된 시점에는 Bass 모형이 더 안정적일 수 있다.

<Part B-2 (2)> : 국내(내국인) HIV/AIDS 확산예측

1. 국내 HIV/AIDS 감염자수(S_t) 시계열 도표




그림 7. 국내(내국인) 연도별 HIV 신규감염자수

내국인 신규감염자수는 2010 년 전후 완만해졌지만 이후에도 700~1,200 명대에서 지속 발생 중이다.

2. 선형성 검토 및 OLS 추정




그림 8. Logistic/Gumbel 선형화 산점도

자료구간	모형	$m^{\wedge}$ (명)	R^2
전체(1985~2024)	Logistic	15,155	0.187
전체(1985~2024)	Gumbel	8,383	0.747
최근 10 년(2015~2024)	Logistic	24,684	0.975
최근 10 년 (2015~2024)	Gumbel	27,769	0.978

$dlnY_t = St/Y(t-1)$ 을 $Y(t-1)$ (Logistic), $lnY(t-1)$ (Gumbel)에 대해 회귀하였다. 전체자료는 $R^2=0.19\sim0.75$ 로 설명력도 약하고 $m^{\wedge}$ 도 2024 년 실제 누적치(20,447 명)보다 작아 모순되지만, 최근 10 년 자료는 $R^2=0.97+$ 로 양호하다.

3. Q-Q plot 기반 (m , μ , σ) 추정




그림 9. m 값 변화에 따른 Logistic/Gumbel 모형의 Q-Q R^2 비교




그림 10. Logistic Q-Q plot

모형	Q-Q 최적 m^*	R^2	μ^*	σ^*	$q^* = 1/\sigma^*$
Logistic	23,978	0.998	2012.93	4.614	0.2167
Gumbel	유한한 최적값 없음	≈ 0.997	—	—	—

앞의 OLS m 을 그대로 쓰지 않고, m 을 변화시켜가며 $t=\mu+\sigma\cdot G^{-1}(U_t)$ 회귀의 R^2 를 극대화하는 m 을 직접 탐색했다(1995~2009 년 구간). Logistic 은 $m=23,978$ 명에서 $R^2=0.998$ 인 뚜렷한 극대점이 존재하지만, Gumbel 은 m 을 키울수록 R^2 가 계속(무한히) 개선되어 유한한 최적 m 을 특정할 수 없었다.

4. 미래 예측 및 모형 적절성 검토




그림 11. Logistic Q-Q 기반 국내 HIV 신규감염자수 미래예측

Gumbel 은 앞선 Q-Q plot 기반 추정에서 m 을 구하지 못해 예측 대상에서 제외하고, Logistic 모형에서 얻은 추정값($m=23,978$, $\mu=2012.93$, $\sigma=4.614$)을 사용해 $\hat{S}(t)$ 를 계산했다. 관측구간 적합도는 $RMSE=167.0$ 으로, b)의 OLS 기반 적합($RMSE=295.9$)보다 뚜렷이 개선되었다. 다만 2020 년 이후 실측치(700~1,000 명대)가 예측 감소곡선보다 계속 높게 유지되어, Logistic 모형도 최근의 장기 고원(plateau) 패턴은 완전히 설명하지 못한다.

2 번의 OLS 와 3 번의 Q-Q plot 기반 추정은 서로 독립적인 추정법으로, Logistic 은 두 방법 모두 유효한 m 을 주지만(최근 10 년 OLS: 24,684 명 vs Q-Q: 23,978 명 — 매우 근접), Gumbel 은 Q-Q 방법으로는 유한한 m 을 특정할 수 없다는 근본적 한계가 드러났다. 따라서 이 자료에는 Logistic 이 Gumbel 보다 안정적이고 일관된 모형이며, Q-Q 기반 Logistic 예측이 OLS 기반 예측보다 관측 적합도가 우수하다.

<Part C (1)> : 영화 흥행 예측 — 왕과 사는 남자

1. 개봉 후 현재까지 일별 관객수(S_t) 및 누적 관객수(Y_t) 시계열 도표




그림 12. '왕과 사는 남자' 개봉 후 일별 관객수 및 누적 관객수

일별 관객수(왼쪽)는 개봉 후 2 주 이내(설 연휴 포함 추정) 여러 차례 급증과 급감을 반복하는 요일효과가 뚜렷하며, 이후 지속적으로 감소한다. 누적관객수(오른쪽)는 전형적인 S 자형 곡선으로, 개봉 후 약 2~3 개월(2026 년 4~5 월경) 만에 최종 관객수(16,922,332 명)에 거의 도달해 포화 상태에 이르렀다.

2. Bass / Logistic / Gumbel / Exponential 모형의 OLS 추정 및 상대오차

휴일효과 보정: 주말·공휴일에는 평일보다 관객이 집중되므로, 해당 날짜를 2 일로 간주해 관객수를 1/2 씩 나눈 동일한 행을 추가하는 방식으로 보정하였다(전체 관객수는 보존하면서 휴일 집중 수요를 시간축상 분산).

기간	Bass	Logistic	Gumbel	Exponential
1 주	1,386,787 (-91.8%)	1,241,653 (-92.7%)	1,409,785 (-91.7%)	23,458,597 (+38.6%)
2 주	추정불가	12,475,136 (-26.3%)	51,071,657 (+201.8%)	추정불가
4 주	16,382,793 (-3.2%)	12,460,126 (-26.4%)	17,716,520 (+4.7%)	추정불가

1 주 자료만으로는 Bass-Logistic-Gumbel 모두 실제의 8~9% 수준으로 심하게 과소추정(-92~-92%)하며, 유일하게 Exponential 만 +38.6%로 그나마 근접했다(모두 부정확한 수준). 2 주 자료에서는 Bass 가 수렴하지 않고, Gumbel 은 오히려 실제의 3 배(+201.8%)로 과대 추정한다. 4 주 자료를 사용하면 Bass 가 -3.2%로 가장 정확해지고 Gumbel 도 +4.7%로 양호해진다. 즉, 자료 기간이 길어질수록(특히 4 주 이상) Bass 모형의 예측 정확도가 뚜렷하게 개선되며, 기간별 최적모형은 1 주=Exponential, 2 주=Logistic, 4 주=Bass(최종적으로 가장 신뢰할 만함)이다.

(Bass 2 주는 OLS 판별식(b^2-4ac)이 음수로 나와 실수 범위의 m^* 을 계산할 수 없었고, Exponential 2-4 주는 음(-)의 m^* 이 나와 총관객수로 해석할 수 없어 각각 '추정불가'로 처리하였다.)

3. 실제 총관객수 m 을 이용한 Q-Q plot 및 모형 적절성 검토

왕과 사는 남자: 실제 총 관객수(m) 기반 Q-Q plot




그림 13. 실제 총관객수 m 을 이용한 4 개 모형 Q-Q plot

4 개 모형 모두 Q-Q plot 의 R^2 가 0.93~0.96 으로 전반적으로 매우 높아, 실제 m 을 대입했을 때 직선에 가깝게 잘 들어맞는다. 그 중 Exponential($R^2=0.956$)과 Bass($R^2=0.954$)가 근소하게 가장 우수하며, Logistic($R^2=0.930$)이 상대적으로 가장 낮다. 이는 이 영화가 이미 상영이 거의 종료된 완결된 확산 곡선을 가지고 있어, 어떤 모형을 적용해도 비교적 적절하게 설명됨을 의미한다.

<Part C (2)> : 영화흥행예측 — 오디세이

1. 개봉 후 현재까지 일별 관객수(S_t) 및 누적 관객수(Y_t) 시계열 도표




그림 14. '오디세이' 개봉 후 일별 관객수 및 누적관객수

일별 관객수(왼쪽)는 주말마다 반복적으로 급등했다가 평일에 급감하는 뚜렷한 요일효과 패턴을 보이며, 아직 감소 추세로 완전히 전환되지 않고 등락을 반복하고 있다. 누적관객수(오른쪽)는 개봉 후 약 1 개월이 지난 현재까지도 뚜렷한 포화 조짐 없이 계속 우상향하고 있어, 왕과 사는 남자와 달리 아직 확산의 초·중반 단계에 있는 것으로 보인다.

2. Bass / Logistic / Gumbel / Exponential 모형의 OLS 추정 및 상대오차

휴일효과 보정: '왕과 사는 남자'와 동일한 방식(주말·공휴일을 2 일로 간주해 관객수를 절반씩 분산)으로 보정하였다.

기간	Bass	Logistic	Gumbel	Exponential
1 주	9,143,009 (-8.8%)	2,606,151 (-74.0%)	2,998,126 (-70.1%)	13,669,542 (+36.3%)
2 주	추정불가	6,676,228 (-33.4%)	8,341,935 (-16.8%)	추정불가
3 주	9,788,413 (-2.4%)	8,160,392 (-18.6%)	9,397,127 (-6.3%)	61,836,313 (+516.6%)


1 주 자료에서는 Bass 가 -8.8%로 가장 근접했고, Logistic-Gumbel 은 실제의 30% 수준으로 과소 추정했다(-70~-74%). 2 주 자료에서는 Bass 모형이 발산해 추정이 불가능했고(계수가 극단적으로 불안정), Gumbel 이 -16.8%로 상대적으로 나왔다. 4 주 자료에서는 Logistic 이 -3.6%로 가장 정확했고, Gumbel 도 +5.3%로 양호했다.

즉, 기간별 최적모형은 1 주=Bass, 2 주=Gumbel, 4 주=Logistic 으로 왕과 사는 남자와 달리 특정 모형이 일관되게 우수하지 않고 기간마다 뒤바뀌는데, 이는 영화가 아직 상영 중이라 확산 곡선의 형태가 안정되지 않았기 때문으로 해석된다.

(Bass 2 주는 계수가 발산해 추정 불가능했고, Exponential 2 주는 음(-)의 m^* 이 나와 비유효 추정치로 판단해 '추정불가'로 처리하였다.)

3. 실제 총관객수 m 을 이용한 Q-Q plot 및 모형 적절성 검토

오디세이: 실제 총 관객수(m) 기반 Q-Q plot






그림 15. '오디세이' 4 개 모형 Q-Q plot

4 개 모형의 Q-Q plot R^2 는 0.38~0.60 으로 왕과 사는 남자(0.93~0.96)에 비해 현저히 낮다. 그 중 Logistic 이 $R^2=0.600$ 으로 가장 높아 상대적 최적모형으로 볼 수 있으나, 절대적 수준에서는 여전히 낮은 편이다. 이는 오디세이가 아직 상영이 종료되지 않아 현재의 누적 관객수(10,027,994 명)를 '최종 총 관객수 m '으로 가정한 것 자체가 부정확하기 때문으로 해석된다 — 즉 어떤 모형도 아직 확정적으로 적절하다고 판단하기 어려우며, 상영이 마무리되어 실제 최종 m 이 확정된 후 재검토가 필요하다.

<Part D> : 수요예측 Shiny Application 만들기




그림 16. 영화 수요 예측 Shiny App 실행 화면

R-shiny App 주소: https://suyeonh.shinyapps.io/project_1/

본 과제에서 분석한 확산모형의 추정 및 예측 결과를 사용자가 직관적으로 확인할 수 있도록 R Shiny 기반의 웹 애플리케이션을 구현하였다. 애플리케이션은 데이터 업로드, 영화 선택, 확산모형 및 추정방법 선택, 모수 확인, 시계열 예측 및 일별 예측값 조회 기능으로 구성하였다.

사용자는 좌측의 Data Upload 메뉴를 통해 분석에 사용할 데이터를 업로드할 수 있으며, 업로드된 데이터에 포함된 영화를 선택하여 분석할 수 있도록 구성하였다. 또한 Bass, Logistic, Gumbel, Exponential 모형 중 원하는 확산모형을 선택할 수 있도록 하였다. 이를 통해 동일한 데이터에 대해 서로 다른 확산모형의 예측 결과를 비교할 수 있다.

각 확산모형에 대해 OLS, Q-Q plot 기반 추정, MLE 등의 추정방법을 선택할 수 있도록 구현하였다. 선택된 추정방법에 따라 확산모형의 주요 모수가 자동으로 계산되며, 분석 결과를 화면에서 즉시 확인할 수 있도록 구성하였다.

또한 Time-Series Forecast 영역에서는 실제 관측값과 모형을 이용한 예측값을 함께 시각화하여 시간에 따른 관객 수의 변화와 향후 추세를 비교할 수 있도록 하였다. 하단의 Predicted Values 표에서는 날짜별 예상 관객 수와 누적 관객 수를 제공하여 구체적인 예측값을 확인할 수 있도록 하였다.